

※自身が知らなかった知識を中心にレポートをまとめている

### 1.線形回帰モデル(199 語)

- ・ある入力（離散あるいは連続値）から出力（連続値）を予測する問題
  - 一直線で予測：線形回帰
  - 一曲線で予測：非線形回帰
- ・線形回帰モデル
  - 教師あり学習
  - 慣例として予測値にはハットをつけ正解データと区別する
- ・線型結合
  - 入力ベクトルとパラメータの内積
  - 未知のパラメータを最小二乗法により推定
  - 説明変数が一次元の場合：単回帰モデル
  - 説明変数が多次元の場合：重回帰モデル
- ・最小二乗法
  - 学習データの平均二乗誤差を最小とするパラメータを探索

### 2.非線形回帰モデル(247 語)

- ・非線形回帰モデル：複雑な非線形構造を内在する現象に対する回帰
  - 基底展開法：回帰関数として基底関数と呼ばれる既知の非線形関数とパラメータベクトルの線型結合を使用
- ・過学習の対策
  - 学習データの数を増やす
  - 不要な基底関数を削除して表現力を抑止
  - 正則化法を利用して表現力を抑止
- ・正則化法
  - ：「モデルの複雑さに伴って、その値が大きくなる正則化項（罰則項）を課した関数」を最小化
  - ・ L2 ノルムを利用（ridge 推定量）：パラメータを 0 に近づけるよう推定（縮小推定）
  - ・ L1 ノルムを利用（lasso 推定量）：いくつかのパラメータを正確に 0 に推定（スパース推定）

### 3.ロジスティック回帰モデル(358 語)

- ・分類問題で使う教師あり学習モデル
  - 入力と  $m$  次元パラメータの線形結合をシグモイド関数に入力する
- ・最尤推定
  - ロジスティック回帰：ベルヌーイ分布の確率分布を使用
  - 生成されるデータは分布のパラメータによって異なる
- ・最尤推定：データからそのデータを生成したであろうもっともらしい分布（パラメータ）を推定

ベルヌーイ分布では、データがわかっている場合確率が未知のパラメータになる  
確率はシグモイド関数となるため、推定するパラメータは重みパラメータになる

- ・ 尤度関数Eを最大とするパラメータを探索  
→ 微分して勾配降下法で求める
- ・ 対数尤度関数の方が微分の計算が楽なので、対数をとって計算する
- ・ 確率的勾配降下法：データを一つずつランダムに選んでパラメータを更新
- ・ モデルの評価：混同行列
- ・ 再現率 (recall)：本当に positive なものの中から positive
- ・ 適合率 (precision)：「positive」だと予測したものの中で本当に positive である割合

#### 4.主成分分析 (132 語)

- ・ 多変量データの持つ構造をより小数個の指標に圧縮  
→ 情報の損失をなるべく小さくする  
→ 小数変数を利用した分析や、2,3次元での可視化が実現可能
- ・ 情報の量を分散の大きさと捉え、線形変換後の変数の分散が最大となる射影軸を探索する
- ・ 寄与率：分散を足し合わせることで、情報損失量の割合を計算する

※5章は講義動画に沿ってk近傍法、k-means法についてまとめている

#### 5.サポートベクターマシン (147 語)

- ・ k近傍法 (kNN)  
→ 教師あり学習  
→ 最近傍のデータをk個持ってきて、それらが最も多く所属するクラスに識別
- ・ k-means 法 (k-平均法)  
→ 教師なし学習  
→ 与えられたデータをk個のクラスタに分類する
- ・ 中心の初期値を変えるとクラスタリング結果も変わり得る  
→ k-means++：初期値の改良
- ・ kの値を変えることで分類数、クラスタリング数も変わる